桂林旅游学院
GUILIN TOURISM UNIVERSITY

本科毕业论文（设计）任务书

题　　目　基于 LightGBM 与特征归因的股票推荐系统

学　　院　[待填写]

专　　业　[待填写]

年　　级　[待填写]

班　　级　[待填写]

姓　　名　[待填写]

学　　号　[待填写]

指导教师　[待填写]　职称　[待填写]

选题类别：　毕业论文　毕业设计（√）　社会调查报告　作品展示　毕业汇报演出　专业外文翻译　（在选定的类型上打√）

注：1.本任务书一式两份，一份学院存档，一份发给学生。

2.任务书均要求打印，表格中书写字体和字号按照以下格式要求执行：段前间距 0.5 行，首行缩进 2 字符，小四号宋体，行距 20 磅。

题　目	基于 LightGBM 与特征归因的股票推荐系统
题目来源	科研课题 生产实际或经济建设（√） 其他 （在选定的类型上打√）

1. 毕业论文（设计）的要求和内容

股票市场受宏观经济波动、产业政策调整、多方投资者博弈及非理性情绪等多重因素影响，呈现出强烈的非线性、高噪声与低信噪比特征。传统的量化多因子选股方法多依托线性多元回归或静态打分机制，难以自适应捕捉因子间的高阶非线性交互与市场状态跃迁；而深度神经网络等复杂黑箱模型虽具备较强的特征拟合能力，但极易在金融时序数据上发生过拟合，更缺乏模型决策的透明度与可解释性，难以满足投资决策审慎风控与金融合规监管的要求。此外，诸多学术与工程实践常因未来数据泄露（前视偏差）、忽视幸存者偏差或缺乏跨周期稳定性检验，导致样本外预测与回测效果严重失真。因此，如何构建一套兼具严密防前视设计、有效截面排序能力、透明特征归因与严谨业绩分解的股票推荐系统，是现代智能金融工程领域亟待解决的核心课题。

针对上述痛点，本毕业设计以 A 股沪深 300 指数成分股为候选标的池，设计并实现一套“特征工程及行业中性化 → 训练期因子诊断 → LightGBM 横截面排序推荐 → 贴合实盘回测与 Alpha/Beta 业绩归因 → TreeSHAP 全局与个股特征归因 → FastAPI 与 Vue3 全栈可视化交互”的全链路股票推荐系统原型。系统的核心任务是实现候选股票的横截面相对排序与 Top-K 推荐，而非预测股票的绝对上涨走势；模型输出二分类打分表示个股未来 5 个交易日收益跑赢当日截面均值的估计倾向，为量化投研人员与投资者提供兼具量化排序支撑与归因解释依据的决策参考。

系统重点围绕以下五个核心模块展开设计与实证研究：（1）数据工程与防泄漏设计：采集沪深 300 成分股自 2015 年 1 月至 2026 年 10 月的日频量价与财务估值数据（共 744,372 条面板样本），特征清洗严格采用向前填充（ffill）并以个股自身历史中位数填补缺失值；财务报表数据严格按照法定披露截止日进行保守滞后对齐（一季报滞后至 4 月 30 日，年报滞后至次年 4 月 30 日）；标签定义为未来 5 个交易日个股收益（t+1 开盘买入至 t+5 收盘）是否跑赢当日截面均值；按时间先后切分训练集、验证集与测试集，并在集合边界设置 5 个交易日的标签成熟期隔离（purging），彻底阻断前视偏差。（2）截面中性化与因子有效性检验：对技术指标、量价衍生指标与基本面因子在每个交易日截面上进行缩尾、行业去均值（行业缺失时退回全市场去均值）与 Z-score 标准化；在训练集内部通过截面 Spearman 秩相关（IC）、Newey-West HAC t 统计量（ICIR×√截面数）及相关性分析（去冗余阈值|r|>0.7）进行因子诊断与筛选，选定 ATR_ratio、MACD_norm、momentum_60d、OBV_zscore 等有效因子；同

时如实记录并分析基本面因子在大样本中性化后未能提供增量的实证现象。（3）LightGBM 排序模型构建与时序验证：基于 Optuna 在训练集内部通过时序交叉验证（TimeSeriesSplit）开展超参数贝叶斯寻优；在测试集上评估 AUC、NDCG@K 与 Precision@K，并与随机猜测、逻辑回归及随机森林基线进行对比；开展 13 轮步长为 120 交易日的推进分析（Walk-Forward 滚动窗口验证），检验模型在不同市场周期下的稳定度。（4）Top-K 组合回测与 Alpha/Beta 业绩归因：构建 Top-K（K=10）等权持仓策略，每 5 个交易日调仓，按下一交易日开盘买入至第 5 交易日收盘卖出收益核算，扣除印花税、佣金及过户费，对比全市场排序与行业中性两种选股口径；将 13 个滚动窗口的预测信号按时间拼接为连续净值序列，对基准收益进行 OLS 线性回归归因，测算 Jensen Alpha 与 Beta 暴露，并分五等分市场状态检验超额收益来源。（5）TreeSHAP 特征归因与原型系统开发：基于 TreeSHAP 算法在 LightGBM 原始 log-odds 空间进行全局特征重要性（Mean |SHAP|）与个股局部归因分解，严格进行加和一致性容差校验；基于 FastAPI 构建后端高性能 REST API 接口，基于 Vue 3 + Vite + ECharts 开发涵盖行情看板、数据工程、因子诊断、模型评测、滚动回测、业绩归因、全局解释与个股 SHAP 归因弹窗的前端交互界面，实现系统原型的完整交付。

本研究秉持实事求是的科学态度，在设计与论文撰写中严格恪守以下规范与局限说明：一是如实报告实验结果，模型滚动 AUC 均值约为 0.5095（38.5%的窗口低于 0.5 随机基线），LightGBM 在排序指标上与随机森林处于统计不可区分的水平，论文不虚夸模型表现；二是深刻揭示业绩归因本质，策略 Beta 为 1.1424（显著大于 1），收益中约 74%由市场 Beta 驱动，Jensen Alpha 年化 2.99%在统计上不显著（p=0.1904），分市场状态下超额随行情严格单调，确认超额源于高 Beta 风险敞口而非纯选股能力，结论符合 A 股半强式有效特征；三是明确数据与回测局限，历史成分股若缺乏动态调整生效期文件则存在幸存者偏差，回测成交未考虑滑点、冲击成本、涨跌停及停牌限制；四是严谨界定特征归因边界，SHAP 值仅反映模型内部对特征的利用权重与边际贡献，不构成经济学因果解释或未来投资收益保证。

2. 研究方案、目标

本项目遵循“理论探究与实证研究相融合、算法建模与系统工程相结合”的研究方案，总体技术路线划分为六个阶段：第一阶段（需求分析与方案设计）：调研量化选股与可解释人工智能（XAI）前沿文献，明确沪深 300 股票池截面推荐的业务定位与功能边界，制定全链路技术方案与数据防泄漏规范。第二阶段（数据工程与因子中性化）：构建面板数据预处理管道，完成缺失值向前填充、财报法定披露截止日保守滞后对齐、标签定义及 5 日时序隔离；实现逐日横截面缩尾、行业去均值中性化与标准化。第三阶段（训练期因子诊断与特征筛选）：在训练期计算候选因子的截面 Spearman IC 与 Newey-West HAC t 值，执行阈值过滤与相关性去冗余，深入剖析技术因子与基

本面因子在截面上的表现差异。第四阶段（LightGBM 建模与滚动时序验证）：运用 Optuna 结合时序交叉验证完成超参数调优，在测试集上开展多模型对比；设计并执行 13 轮 Walk-Forward 滚动窗口推进实验，统计跨期 AUC 分布与因子符号翻转情况。第五阶段（实盘级回测与业绩归因实证）：设计考虑交易摩擦成本的 Top-K 等权调仓回测机制，对比全市场排序与行业中性选股表现；对滚动拼接净值开展市场基准回归，解耦 Jensen Alpha 与 Beta 风险暴露，并按市场状态五等分检验收益单调性。第六阶段（TreeSHAP 特征归因与系统原型交付）：在 log-odds 空间实现 TreeSHAP 全局与个股局部解释，严格执行加和一致性校验；采用 FastAPI 与 Vue 3 构建 RESTful 微服务与组件化前端，完成系统集成、联调与毕业论文撰写。

本研究预期达成以下四项核心目标：（1）理论与方法目标：建立一套规范严密、杜绝前视偏差的 A 股量化排序建模范式，通过因子诊断、时序切分、滚动验证与 Alpha/Beta 业绩解耦，揭示机器学习在 A 股弱信号环境下的真实预测边界与市场有效性特征。（2）算法与模型目标：构建收敛稳定、支持时序交叉验证的 LightGBM 股票推荐模型，客观对比基线指标，完成 13 轮 Walk-Forward 推进实验，全面评估模型排序能力与跨周期平稳性。（3）可解释性与归因目标：实现基于 TreeSHAP 的特征归因模块，全局明确主要影响因子的贡献占比，局部实现个股推荐打分的透明化拆解，并通过加和性数学校验确保解释可信度。（4）工程系统与交付目标：完成一套功能完备、前后端分离的股票推荐与特征归因原型系统开发，输出规范的 API 接口与交互界面，提交包含真实可复现实验产物的高质量毕业设计论文。

3. 毕业论文进度计划

序号	各阶段工作内容	起讫日期
1	制定本学院 2026 届毕业论文（设计）工作计划和实施细则，报教务处备案。	2025 年 12 月 01 日—2025 年 12 月 07 日
2	1. 各学院选聘毕业论文（设计）指导教师，组织命题、专家审题工作。 2. 组织学生完成选题，确定指导关系。 3. 命题表和选题汇总表报教务处备案。	2025 年 12 月 08 日—2025 年 12 月 16 日
3	撰写开题报告	2025 年 12 月 17 日—2025 年 12 月 25 日
4	开题答辩	2025 年 12 月 26 日—2025 年 12 月 28 日
5	撰写初稿	2025 年 12 月 29 日—2026 年 2 月 28 日
6	中期检查	2026 年 2 月 29 日—2026 年 3 月 15 日
7	定稿和查重	2026 年 3 月 16 日—2026 年 4 月 15 日

8	开展答辩	2026 年 4 月 16 日—2026 年 4 月 30 日

4. 主要参考资料

［1］ Ke G, Meng Q, Finley T, et al. LightGBM: A highly efficient gradient boosting decision tree[C]//Advances in Neural Information Processing Systems (NeurIPS 2017). Long Beach: Curran Associates, Inc., 2017, 30: 3146-3154.

［2］ Lundberg S M, Lee S I. A unified approach to interpreting model predictions[C]//Advances in Neural Information Processing Systems (NeurIPS 2017). Long Beach: Curran Associates, Inc., 2017, 30: 4765-4774.

［3］ Lundberg S M, Erion G, Chen H, et al. From local explanations to global understanding with explainable AI for trees[J]. Nature Machine Intelligence, 2020, 2(1): 56-67. DOI: 10.1038/s42256-019-0138-9.

［4］ Gu S, Kelly B, Xiu D. Empirical asset pricing via machine learning[J]. The Review of Financial Studies, 2020, 33(5): 2223-2273. DOI: 10.1093/rfs/hhaa009.

［5］ Fama E F, French K R. Common risk factors in the returns on stocks and bonds[J]. Journal of Financial Economics, 1993, 33(1): 3-56. DOI: 10.1016/0304-405X(93)90023-5.

［6］ Harvey C R, Liu Y, Zhu H. … and the cross-section of expected stock returns[J]. The Review of Financial Studies, 2016, 29(1): 5-68. DOI: 10.1093/rfs/hhv059.

［7］ Akiba T, Sano S, Yanase T, et al. Optuna: A next-generation hyperparameter optimization framework[C]//Proceedings of the 25th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining. Anchorage: ACM, 2019: 2623-2631. DOI: 10.1145/3292500.3330701.

［8］ López de Prado M. Advances in financial machine learning[M]. Hoboken: John Wiley & Sons, 2018.

［9］ Newey W K, West K D. A simple, positive semi-definite, heteroskedasticity and autocorrelation consistent covariance matrix[J]. Econometrica, 1987, 55(3): 703-708. DOI: 10.2307/1913610.

［10］ Järvelin K, Kekäläinen J. Cumulated gain-based evaluation of IR techniques[J]. ACM Transactions on Information Systems, 2002, 20(4): 422-446. DOI:

10.1145/582415.582418.

［11］ Caruana R, Lou Y, Gehrke J, et al. Intelligible models for healthcare: Predicting pneumonia risk and 30-day hospital readmission[C]//Proceedings of the 21th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining. Sydney: ACM, 2015: 1721-1730. DOI: 10.1145/2783258.2788613.

［12］ Fischer T, Krauss C. Deep learning with long short-term memory networks for financial market predictions[J]. European Journal of Operational Research, 2018, 270(2): 654-669. DOI: 10.1016/j.ejor.2017.11.026.

［13］ Burges C, Shaked T, Renshaw E, et al. Learning to rank using gradient descent[C]//Proceedings of the 22nd International Conference on Machine Learning. Bonn: ACM, 2005: 89-96. DOI: 10.1145/1102351.1102363.

［14］ 周志华. 机器学习[M]. 北京: 清华大学出版社, 2016.

［15］ 曹志鹏, 范思雨. 机器学习在中国股票市场的多因子选股研究[J]. 清华金融评论, 2021(06): 101-104. DOI: 10.19409/j.cnki.thf-review.2021.06.026.

［16］ 肖争艳, 涂强. 机器学习在资产定价中的应用: 国际前沿与中国实践[J]. 经济学动态, 2021(05): 133-149.

［17］ 周颖, 欧阳红兵. 基于可解释机器学习的中国 A 股市场选股策略研究[J]. 管理科学学报, 2022, 25(08): 65-82.

［18］ 郑振龙, 孙清泉. 股票收益率的横截面特征与系统性风险——基于 Fama-MacBeth 检验[J]. 财贸经济, 2018, 39(04): 50-65. DOI: 10.19795/j.cnki.cn11-1166/f.2018.04.004.

［19］ 徐龙炳, 陆蓉. 资本资产定价模型与中国股市“异象”[J]. 经济研究, 2020, 55(02): 134-149.

［20］ 杨博理, 贾芳. 量化炼金术: 中低频量化交易策略研发[M]. 北京: 机械工业出版社, 2020.

［21］ 余柏翱. 基于机器学习的多因子量化选股策略研究[D]. 桂林: 桂林旅游学院, 2024.

［22］ 文晓婷. 基于 LightGBM 与 XGBoost 的 ESG 多因子选股择时策略实证研究[D].

桂林: 桂林旅游学院, 2024.

在论文写作期间应遵守的相关规定

1.严格遵守学校的各项规章制度及学生手册中的各项要求，注意安全。

2.严格遵守实习单位的各项规章制度，尊重实习单位的指导老师，服从各项工作安排，积极完成工作任务。

3.服从论文指导小组的工作进程安排，按时、按质完成论文及相关任务。

4.注意对相关被调查人、企业的信息保密，不得违反著作法、专利法等相关法律法规，严禁剽窃、抄袭他人研究、著作成果。

教研室意见	教研室主任签字：　　[待填写]年[待填写]月[待填写]日		
学院意见	学院领导签字：　　[待填写]年[待填写]月[待填写]日		
任务书下达时间	[待填写]年[待填写]月[待填写]日	**完成毕业论文时间**	[待填写]年[待填写]月[待填写]日

注：任务书由指导教师填写